


Nandisya Faiz Effendi

Data Scientist | Software Developer

PORTFOLIO

Hybrid Retrieval pada RAG studi kasus UU Ketenagakerjaan



Role: AI Engineer/Researcher

Implementasi Hybrid Retrieval dalam RAG untuk Chatbot terkait UU Ketenagakerjaan Indonesia


- Tech Stack



- Background

Indonesia memasuki fase **bonus demografi**, Dukcapil (2024) mencatat **usia produktif (15-64 tahun)** mencapai 196 juta jiwa atau **69,58% populasi di Indonesia**. Sayangnya, hal ini juga dibarengi permasalahan seperti **88 ribu pekerja yang terkena PHK sepanjang tahun 2025** berdasarkan Kementrian Ketenagakerjaan Indonesia. Mardiyati (2023) mengatakan **kurangnya pemahaman tenaga kerja** di Indonesia tentang hak dan kewajibannya sering berakibat pada **ketidaksadaran mereka terhadap pelanggaran hak-haknya**.

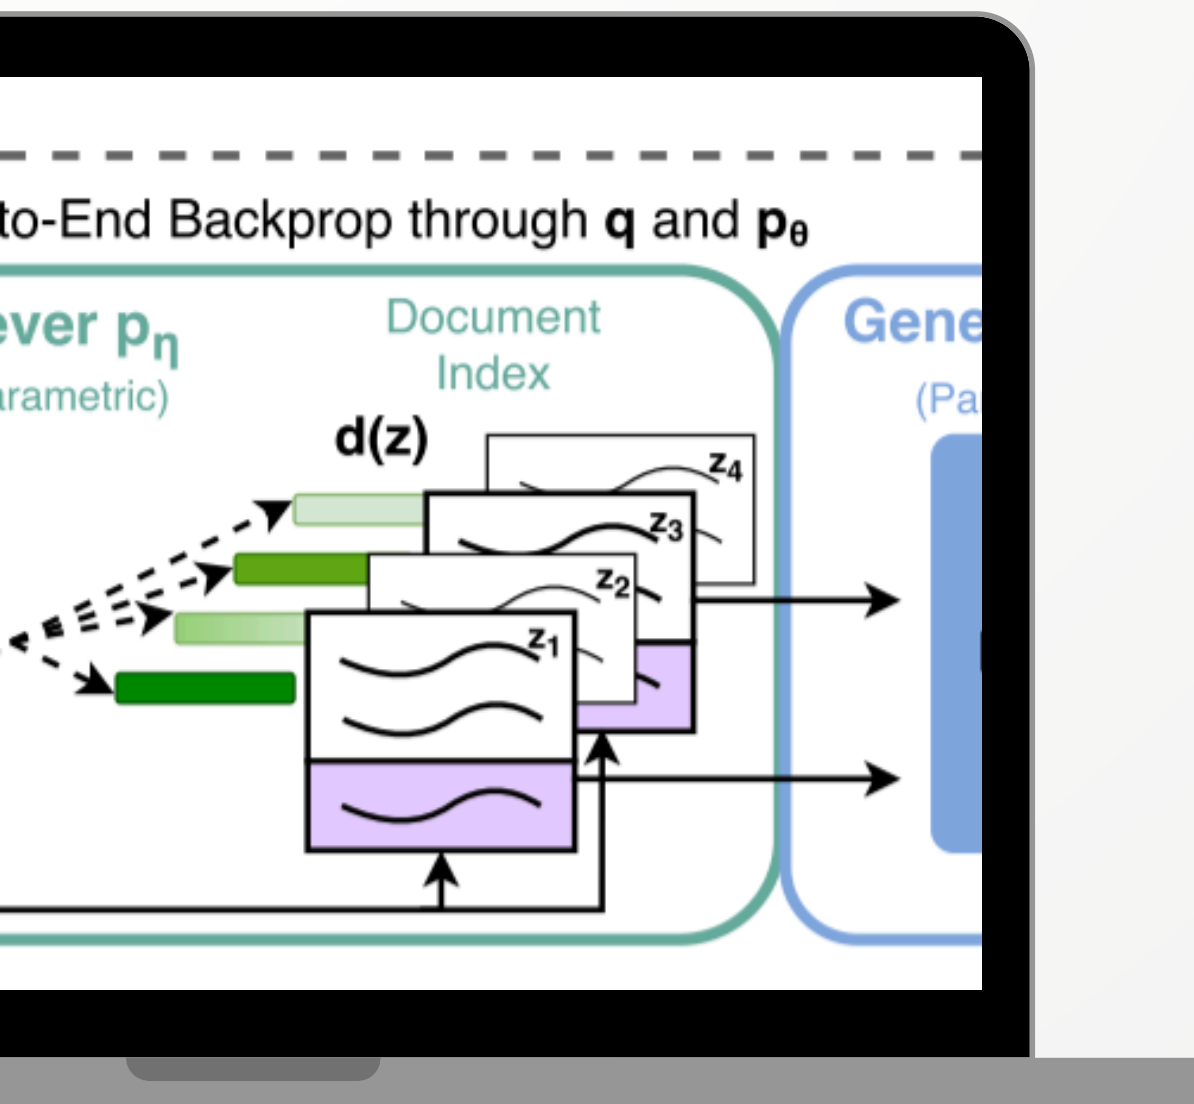
Microsoft melaporkan pada tahun 2025 **pengguna generative AI termasuk LLM** mencapai **30% populasi dunia**. Hal tersebut menggambarkan bahwa **LLM sudah masuk ke berbagai domain spesifik** dan berpotensi **mengatasi permasalahan gap informasi antara pekerja** dengan **undang-undang terkait**.



Hybrid RAG

- **Problem Statement**

- 1 Pengguna LLM yang meningkat juga menghadirkan **tantangan**, khususnya ketika model menghasilkan **respons yang meyakinkan** tetapi **tidak didukung oleh fakta yang jelas**, fenomena yang dikenal sebagai **AI Hallucination** (Gao et al., 2024).
- 2 Arsitektur seperti **Retrieval augmented generation (RAG)** menggabungkan **pengetahuan parameterized** dengan **non-parameterized** untuk mengatasi hallucination pada LLM (Gao et al., 2024; Lewis et al., 2021). **Namun, RAG berbasis vektor** dinilai **kurang baik** untuk pertanyaan yang **membutuhkan konteks global** dan **hubungan antar konteks** (Edge et al., 2025).



- Approach and Proposed Solution

State of The Art


Pendekatan lain seperti **RAG berbasis *knowledge graph*** menawarkan **kelebihan unik dalam mengelola pengetahuan relasional** melalui penerapan teknik analisis graf, seperti **Graph Traversal Search** dan **Community Detection** (Wang et al., 2023; Edge et al., 2025).

Sejumlah penelitian mulai melakukan **pendekatan baru** menggunakan pendekatan **hybrid retrieval berbasis graph dan vektor** yang memungkinkan retriever melakukan **pencarian berbasis vektor** dengan tetap **mempertimbangkan relasi antar konteks**.

Hybrid Retrieval as Proposed Solution

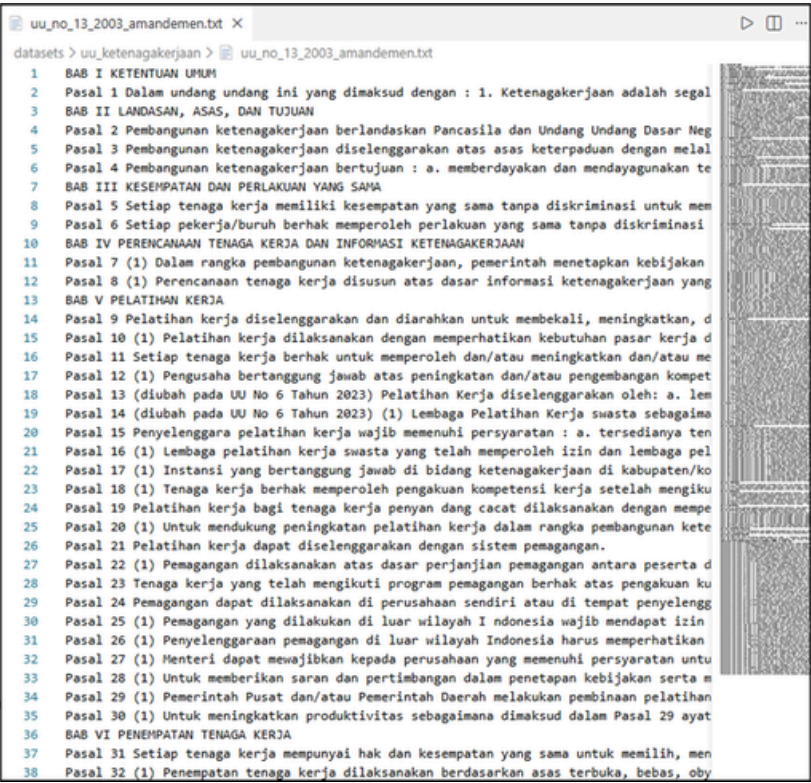
Maka, **arsitektur hybrid graph dan vector retrieval** diajukan dalam proyek ini **untuk menangani relasi yang dimiliki konteks berupa dokumen UU Ketenagakerjaan** melalui knowledge graph.

• Data Overview



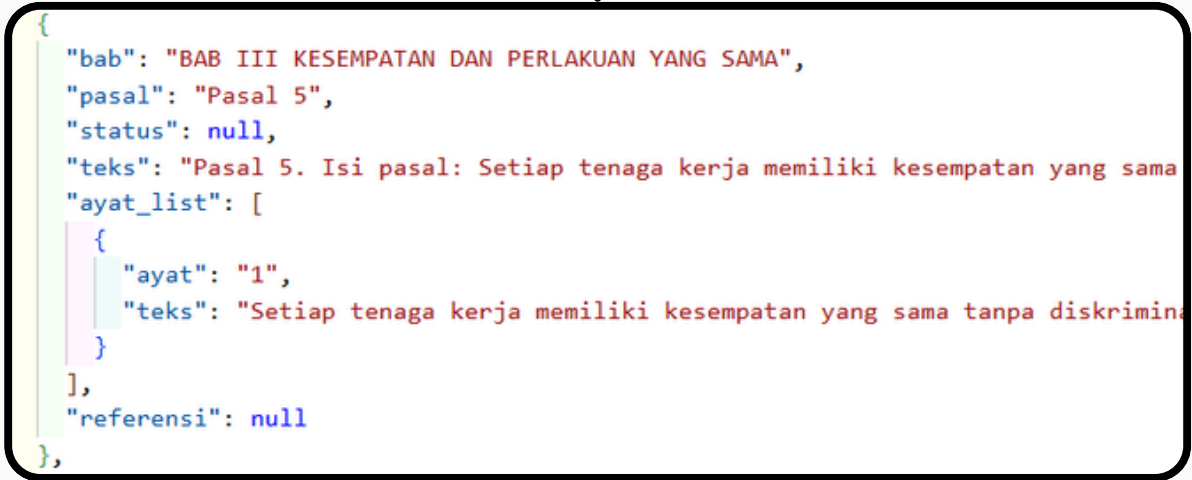
PDF UU No. 13 Tahun 2003 tentang Ketenagakerjaan

Preprocessing dengan
Regex




UU Ketenagakerjaan Amandemen
dengan UU Cipta Kerja

Strukturisasi data dengan
Regex

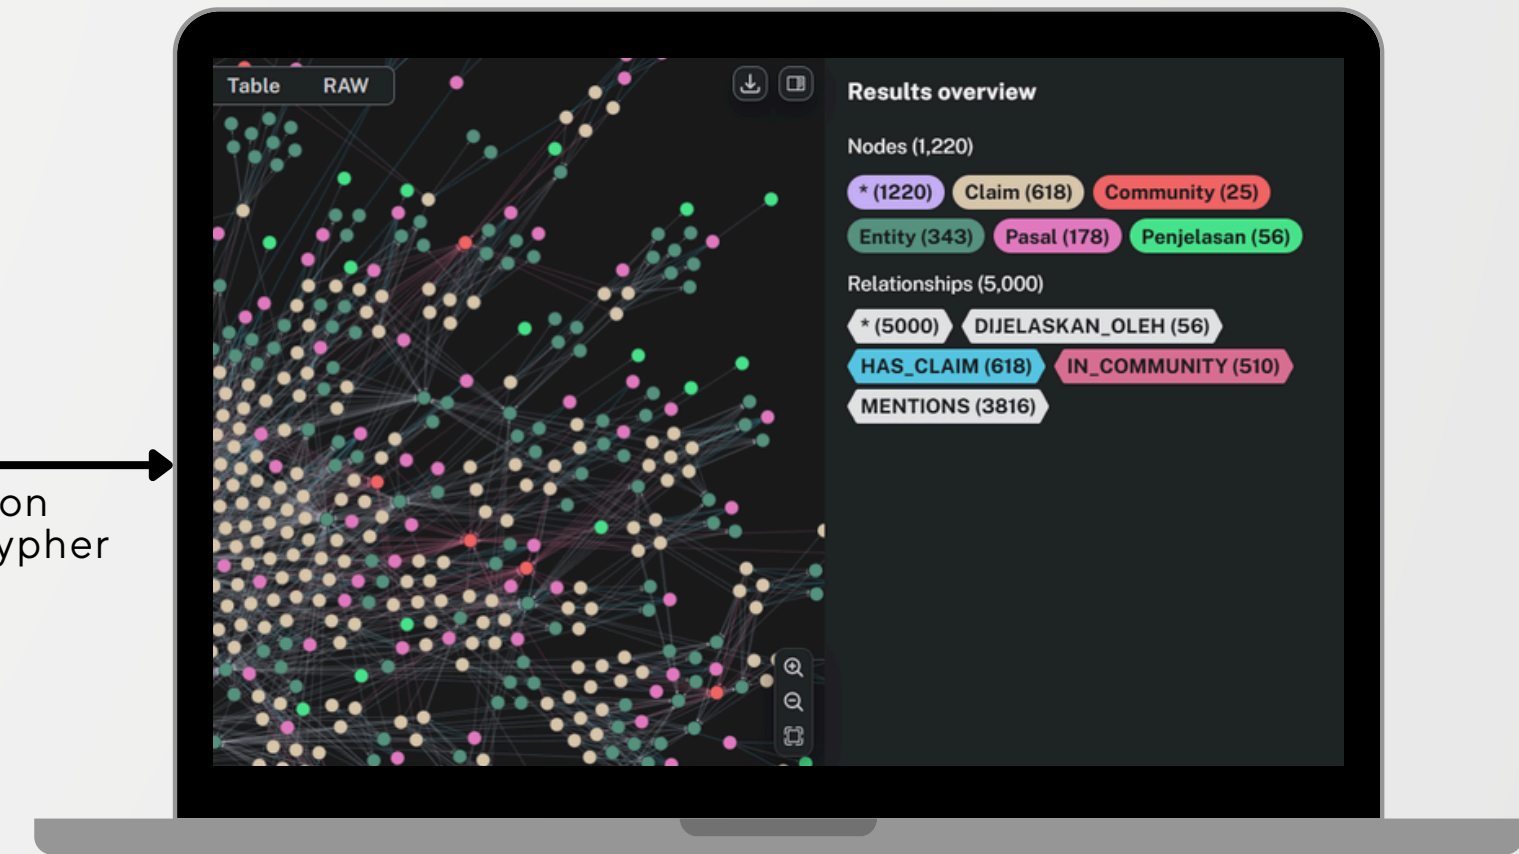


Dataset Final berupa 241 pasal dalam JSON

Flow of Building A Knowledge Graph



Graph Ingestion
menggunakan Cypher
Query



Final Knowledge Graph on Neo4j graph database

Knowledge graph (KG) akan menjadi database utama pada proses retrieval. Pada flowchart proses pengembangan KG mulai dari proses ekstraksi hingga graph ingestion ke Neo4j sebagai penyedia layanan graph database. Neo4j digunakan karena mendukung pemodelan knowledge graph dan traversal relasi yang efektif sebagai dasar retrieval berbasis graf.

- Why Leiden Community Detection?



Community detection digunakan untuk menemukan struktur dari jaringan graph yang kompleks dan berskala besar. **Algoritma Leiden dipilih karena** merupakan penyempurnaan dari algortima sebelumnya Louvain dengan tujuan utama untuk **menjamin bahwa komunitas yang dihasilkan memiliki keterhubungan internal yang baik** (Traag et al., 2019).


$$Q = \sum_c \left[\left(w_c - \gamma \left(\frac{n_c(n_c-1)}{2} \right) \right) \right]$$

- Keterangan:
- Q : fungsi kualitas graf terhadap partisi komunitas (CPM)
 - w_c : total bobot edge dalam komunitas c
 - n_c : jumlah node dalam komunitas c
 - γ : *resolution* parameter

Formula CPM untuk memperoleh kualitas suatu graph community


Paper Leiden Community Detection
oleh Traag et al., (2019)

- System Architecture



Hybrid retrieval (Ongris et al., 2025) akan diimplementasikan ke dalam RAG, pada proyek ini dengan **menggabungkan** konsep **graph dan community detection** dengan teknik **pencarian berbasis vektor**.

Proses dimulai dengan **input pertanyaan pengguna** yang kemudian **di ekstrak untuk menemukan entitas** didalamnya. **Entitas yang ditemukan** akan menjadi seed node untuk melakukan **pencarian dalam knowledge graph** hingga **pencarian kesamaan semantik** dengan **formula cosine similarity** antara pertanyaan dan fakta hukum dalam knowledge graph



$$\text{similarity}(A, B) = \frac{A \cdot B}{||A|| ||B||}$$

Keterangan:

A, B : vektor embedding

Formula cosine similarity untuk mencari kesamaan semantik antara 2 vektor hasil teks embedding

System Evaluation

No	Pertanyaan Uji	Ground Truth
1	Apa syarat pekerja bisa melakukan cuti tahunan?	Pengusaha wajib memberikan cuti tahunan kepada pekerja setelah pekerja yang bersangkutan bekerja selama 12 bulan secara terus menerus.
2	Bagaimana ketentuan mengenai waktu kerja lembur?	Kerja lembur hanya dapat dilakukan dengan persetujuan pekerja/buruh. Waktu kerja lembur dibatasi paling banyak 4 jam sehari dan 18 jam seminggu, dan pengusaha wajib membayar upah lembur.
3	Apa hak pekerja perempuan selama masa haid dan melahirkan?	Pekerja perempuan berhak tidak bekerja pada hari pertama dan kedua haid jika mengalami keluhan. Berhak istirahat 1,5 bulan sebelum dan sesudah melahirkan, serta istirahat sesuai surat dokter jika mengalami keguguran. Pengusaha wajib memberikan kesempatan menyusui selama waktu kerja.
4	Bagaimana peraturan mengenai pemutusan hubungan kerja (PHK) secara sepihak oleh pengusaha?	PHK harus diberitahukan kepada pekerja/buruh dan disertai alasan sah sesuai peraturan perundang-undangan. Jika dilakukan sepihak tanpa alasan sah, pengusaha wajib membayar ganti kerugian.
5	Bagaimana ketentuan tentang upah minimum?	Upah minimum ditetapkan oleh gubernur dengan mempertimbangkan kondisi ekonomi dan ketenagakerjaan berdasarkan formula yang ditentukan pemerintah. Ketentuan lebih lanjut mengenai formula penghitungan Upah minimum diatur dalam Peraturan Pemerintah.
6	Berapa usia anak yang boleh bekerja?	Anak berusia antara 13 sampai 15 tahun dapat melakukan pekerjaan ringan, dengan syarat tidak mengganggu perkembangan fisik, mental, dan sosialnya.
7	Apa hak pekerja yang mengalami disabilitas?	Pekerja penyandang disabilitas berhak memperoleh perlakuan dan perlindungan yang sesuai dengan jenis dan derajat disabilitasnya.
8	Apa kewajiban pengusaha terhadap pekerja yang bekerja pada hari libur?	Pengusaha yang mempekerjakan pekerja pada hari libur resmi wajib membayar upah kerja lembur.
9	Kapan perjanjian kerja berakhir?	Perjanjian kerja berakhir apabila: pekerja meninggal dunia, jangka waktu perjanjian habis, atau adanya

Sistem akan diuji menggunakan **18 Pertanyaan Uji dan ground truth** (jawaban acuan) yang didapat dari website **HukumOnline** dan **telah divalidasi oleh ahli** pada penelitian sebelumnya oleh Mukti P. (2025)

System Evaluation



RAG Assesment (RAGAS) merupakan serangkaian **metrik evaluasi (evaluation framework) populer** yang digunakan **untuk mengukur kinerja aplikasi LLM**. Metrik-metrik yang ada dirancang untuk mengukur kinerja aplikasi LLM secara objektif (VibrantLabs, 2024).

$$answer\ relevancy = \frac{1}{N} \sum_{i=1}^N \frac{E_{g_i} \cdot E_o}{||E_{g_i}|| ||E_o||}$$

Keterangan:

E_{g_i} : embedding jawaban


E_o : embedding input

N : banyak jawaban yang dibuat

Dengan metrik Answer Relevancy dari framework RAGAS, dapat diukur secara objektif **seberapa relevan jawaban** yang di **generate aplikasi LLM** dengan **input yang dimasukan pengguna**


System Evaluation

No	Konfigurasi Sistem	Tujuan Ablasi	Answer Relevancy
1	GPT-4o-mini	Perbandingan Dasar	72,7%
2	Vector RAG	Efek penambahan memori non-parametric dengan vector search	86,6%
3	Hybrid RAG	Efek penambahan memori non-parametric dengan community search	90,3%



Dapat dilihat sistem usulan (Hybrid RAG) **meningkatkan performa Answer Relevancy sebesar 17,6%** jika dibandingkan dengan model bahasa ringan (GPT-4o-mini), serta peningkatan 3,7% jika dibandingkan dengan sistem sebelumnya

System Evaluation



Biaya untuk tiap 1 juta token (OpenAI, 2026):

Model	Input	Cached input	Output
gpt-4o-mini	\$0.15	\$0.075	\$0.60

Skor Answer Relevancy tinggi 90,3% didapat oleh sistem Hybrid RAG yang menggunakan LLM GPT-40-mini, model tersebut **hanya memerlukan biaya \$0.60 untuk setiap 1 juta token output.**

System Evaluation


No	Pertanyaan Uji	GPT-4o-mini	Hybrid RAG
1	Apa syarat pekerja bisa melakukan cuti tahunan?	0,661	0,837
2	Bagaimana ketentuan mengenai waktu kerja lembur?	0,599	0,848
3	Apa hak pekerja perempuan selama masa haid dan melahirkan?	0,861	0,872
4	Bagaimana peraturan mengenai pemutusan hubungan kerja (PHK) secara sepihak oleh pengusaha?	0,694	0,872
5	Bagaimana ketentuan tentang upah minimum?	0,822	0,824
6	Berapa usia anak yang boleh bekerja?	0,704	0,875
7	Apa hak pekerja yang mengalami disabilitas?	0,770	0,967
8	Apa kewajiban pengusaha terhadap pekerja yang bekerja pada hari libur?	0,746	0,962
9	Kapan perjanjian kerja berakhir?	0,665	0,844
10	Apa hak pekerja setelah mengikuti program pemagangan?	0,909	0,988
11	Apa saja alasan sah PHK?	0,766	0,774
12	Karyawan meninggal dunia, apa saja hak ahli warisnya?	0,824	0,826

Arsitektur **Hybrid RAG** secara konsisten **mengungguli kemampuan dasar model GPT-4o-mini pada seluruh skenario uji**. sistem terbukti mampu menekan tingkat halusinasi base LLM dan memastikan jawaban berlandaskan pada struktur Undang-Undang yang valid.

Nandisya Faiz Effendi

Data Scientist | Software Developer

Final Product using Python Streamlit



Reference

- Mardiyati, S. (2023). Jaminan Hak Pekerja Yang Terkena Pemutusan Hubungan Kerja Dalam Perjanjian Kerja Waktu Tertentu. Disiplin: Majalah Civitas Akademika Sekolah Tinggi Ilmu Hukum Sumpah Pemuda.
- Gao, Y., Xiong, Y., Gao, X., Jia, K., Pan, J., Bi, Y., Dai, Y., Sun, J., Wang, M., & Wang, H. (2024). Retrieval-Augmented Generation for Large Language Models: A Survey. <http://arxiv.org/abs/2312.10997>
- Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W., Rocktäschel, T., Riedel, S., & Kiela, D. (2021a). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. <http://arxiv.org/abs/2005.11401>
- Edge, D., Trinh, H., Cheng, N., Bradley, J., Chao, A., Mody, A., Truitt, S., Metropolitansky, D., Ness, R. O., & Larson, J. (2025). From Local to Global: A Graph RAG Approach to Query-Focused Summarization. <http://arxiv.org/abs/2404.16130>
- Wang, L., Yang, N., Huang, X., Jiao, B., Yang, L., Jiang, D., Majumder, R., & Wei, F. (2024). Text Embeddings by Weakly-Supervised Contrastive Pre-training. <http://arxiv.org/abs/2212.03533>
- Ongris, J. G., Darari, F., Tobing, B. C. L., Faisal, D. R., & Lee, O. (2025). Benchmarking KG-based RAG Systems: A Case Study of Legal Documents. <https://github.com/OSU-NLP-Group/HippoRAG>
- Traag, V., Waltman, L., & van Eck, N. J. (2019). From Louvain to Leiden: guaranteeing well-connected communities. <https://doi.org/10.1038/s41598-019-41695-z>